


Universidad Mayor de San Simón
Facultad de Ciencias y Tecnología
Ingeniera Informática



DETECCIÓN DE INCENDIOS EN ÁREAS FORESTALES

Proyecto de grado

Presentado por:

Univ. Castro Arnez Juan Manuel

Tutor:

Di Santi Eduardo Phd.

Cochabamba - Bolivia

Agosto 2016

*Dedicado a
mi familia*

AGRADECIMIENTOS

Muchas gracias a todos!

Índice general

AGRADECIMIENTOS	III
ÍNDICE DE FIGURAS	VII
ÍNDICE DE TABLAS	IX
RESUMEN	XI
1. INTRODUCCIÓN	1
1.1. Descripción del problema	1
1.2. Objetivos	1
1.2.1. Objetivo general	1
1.2.2. Objetivos específicos	2
1.3. Justificación	2
1.4. Límites y alcances	2
1.5. Método de investigación	2
2. MARCO TEÓRICO	3
2.1. Definiciones	3
2.2. Incendios forestales	3
2.3. Detección de incendios forestales	4
2.3.1. Características del fuego	5
2.3.2. Características del humo	5
2.3.3. Desafíos en la detección de incendios	6
2.4. Visión por Computador	7
2.4.1. Tratamiento de imágenes	7
2.4.2. Descriptor de características	11
2.5. Aprendizaje Supervisado	11

2.5.1.	Maquina de Soporte Vectorial	12
2.5.2.	Red Neuronal Artificial	12
2.6.	Estado del arte	12
2.7.	Resumen del capitulo	12
3.	DESARROLLO DEL SISTEMA DE DETECCIÓN	15
3.1.	Contexto del ambiente de desarrollo	15
3.2.	Alcance del sistema de detección	16
3.3.	Diseño del sistema de detección	17
3.3.1.	Diagrama de procesos	17
3.3.2.	Rol de actividades	20
3.4.	Generación del modelo	21
3.4.1.	Selección de imágenes	21
3.4.2.	Entrenamiento	23
3.4.3.	Refinación	24
3.5.	Implementación del sistema de detección	27
3.5.1.	Establecer las regiones de interés	28
3.5.2.	Generación de candidatos	28
3.5.3.	Extracción de características	29
3.5.4.	Clasificación de candidatos	29
3.5.5.	Refinación de la clasificación	30
3.6.	Resumen del capitulo	30
4.	EXPERIMENTACIÓN Y EVALUACIÓN	31
4.1.	Pruebas	31
4.2.	Matriz de confusión	31
4.3.	Rendimiento del clasificador	33
4.3.1.	Exactitud	33
4.3.2.	Precisión	33
4.3.3.	Tasa de detección	34
4.3.4.	Especificidad	34
4.4.	Evaluación del sistema de detección	35
4.4.1.	Tasa de detección	35
4.4.2.	Tasa de Error	35
4.4.3.	Falsos positivos por imagen	35
4.5.	Casos de estudio	35
5.	CONCLUSIONES Y RECOMENDACIONES	37

Índice de figuras

2.1. Sección de la imagen que sera recortada.	8
2.2. Colección de imágenes obtenidas después del recorte.	9
2.3. Imagen original.	9
2.4. Imagen después de la puesta en escala.	10
2.5. Imagen original.	10
2.6. Imagen reflejada.	10
3.1. Sección de la imagen que sera recortada.	18
3.2. Sección de la imagen que sera recortada.	19
3.3. Sección de la imagen que sera recortada.	20
3.4. Sección de la imagen que sera recortada.	23
3.5. Sección de la imagen que sera recortada.	24
3.6. Sección de la imagen que sera recortada.	25
3.7. Sección de la imagen que sera recortada.	26
3.8. Sección de la imagen que sera recortada.	27
4.1. Sección de la imagen que sera recortada.	32

Índice de cuadros

3.1. Rol de actividades.	21
----------------------------------	----

RESUMEN

Esta tesis describe un sistema para la detección de incendios en áreas forestales que puede ser implementado usando métodos de visión por computadora. El objetivo es crear un sistema que procese una entrada de vídeo que puede estar en un lugar estático o en un dron.

Se presentan antecedentes de incendios forestales de todo el mundo, y se examina cada situación donde se utilizan capturas de vídeo durante o después de que el desastre se ha producido. Hasta la fecha, los drones no han jugado un papel central en el seguimiento de áreas forestales para detectar anomalías que puedan llegar a generar incendios forestales.

El propósito del sistema de detección de incendios forestales debe ser capaz de otorgar alerta y ayuda visual para las personas que tienen acceso al sistema. Se espera que esto aumente la capacidad de reacción de las entidades pertinentes para que el incendio sea controlado lo mas pronto posible.

El sistema de detección consta de 2 módulos, el primero esta centrado en la búsqueda de fuego y el segundo en la detección de humo.

La combinación de estos módulos logran un XX de porcentaje de detección de incendios forestales con una variedad de imágenes de incendios forestales.

Capítulo 1

INTRODUCCIÓN

La combinación de estos módulos logran un XX de porcentaje de detección de incendios forestales con una variedad de imágenes de incendios forestales. blallbalbalb

1.1. Descripción del problema

1.2. Objetivos

1.2.1. Objetivo general

Desarrollar un sistema de detección de incendios en áreas forestales, mediante el uso de técnicas de Visión por Computador y Aprendizaje Supervisado.

1.2.2. Objetivos específicos

1. Identificar las características de los incendios mediante técnicas de Visión por Computador.
2. Modelar la detección de incendios mediante Aprendizaje Supervisado.
3. Integrar las técnicas de Visión por Computador y los modelos de detección de incendios.
4. Realizar un análisis de los resultados de la experimentación realizada en una muestra de imágenes.

1.3. Justificación

1.4. Límites y alcances

1.5. Método de investigación

Esta investigación se realiza con un enfoque experimental donde en base al planteamiento del problema, se formula la hipótesis de detección visual de incendios mediante técnicas de Visión por Computador y Aprendizaje Automático.

El diseño metodológico presentado en la imagen refleja el esquema de trabajo seguido durante todo el desarrollo del presente proyecto de grado.

Capítulo 2

MARCO TEÓRICO

En este capítulo abordaremos los conceptos necesarios que se necesitan para comprender el funcionamiento de un sistema de detección visual, las características del caso de estudio y los diferentes proyectos e investigaciones realizadas sobre la detección de incendios.

Es necesario comprender la manera en que los componentes visuales de los incendios se comportan, el desafío que su detección representa para un sistema informático y realizar un estudio de los métodos y técnicas mas eficaces para su procesamiento y detección.

2.1. Definiciones

2.2. Incendios forestales

Un incendio forestal es la presencia de fuego que consume todo aquello que este cerca y que genere combustión en un terreno forestal. Factores como el tipo de terreno y la velocidad del viento son importantes, y aunque

un incendio forestal se genera de manera natural debido a la excesiva acumulación de materia orgánica seca, la mayoría de los incendios forestales son causados por el hombre. El descuido de las personas al visitar zonas forestales abandonando desechos combustibles y actos de vandalismo son los principales factores que influyen en el aumento de riesgo de que ocurra un incendio forestal.

Los incendios no solo afectan la vegetación, sino también las zonas húmedas debido al aumento de cenizas y polvo, los suelos pierden condiciones de acumulación de agua ocasionando que se degraden fácilmente, se pierde el hábitat de los animales silvestres y se produce la muerte de especies vegetales, animales e incluso vidas humanas.

2.3. Detección de incendios forestales

Esta sección cubre detalles de los elementos visuales que conforman un incendio, el estudio de estos elementos permitió elegir de manera adecuada los métodos y técnicas para su procesamiento y detección.

Una detección temprana de incendios forestales, aumenta la probabilidad de que el combate al mismo sea exitoso y el daño producido sea mínimo. La forma y tamaño de un incendio depende de la temperatura de combustión, la cantidad de suministro de oxígeno y principalmente de los componentes químicos del combustible, es este combustible el que no varía demasiado en áreas forestales y está principalmente afectado por la época del año ya que esto definirá la velocidad con la cual se realiza la combustión.

Un incendio forestal, presenta muchas características tales como la temperatura o humedad, pero al tratarse de un sistema visual es necesario centrarse y realizar un estudio de las características visuales del fuego y humo.

2.3.1. Características del fuego

El fuego se produce cuando ocurre la combustión de un elemento inflamable, este desprende una emisión de luz que puede ser muy intensa, el rasgo visual mas característico del fuego es su color, que pueden variar en incendios forestales desde un tono amarillo a naranja.

Aunque en las áreas forestales, no hay objetos naturales con los colores de una llama, es necesario que el sistema pueda distinguir objetos que presenten estos tonos de colores y que sepan diferenciarlos de una llama, para lograr esto es necesario realizar un estudio de otras características de una llama, como los bordes y su variación de color.

2.3.2. Características del humo

El humo se compone principalmente de pequeñas partículas de carbón vegetal completamente quemados y el polvo quemado de modo incompleto. Para los combustibles que normalmente se hallan en áreas forestales, el color del humo se extiende desde un blanco a gris dependiendo de la temperatura del incendio. Si el material está completamente quemado el humo sera semi-transparente y cuando el material esta quemado de forma incompleta, se genera un humo entre semi-transparente a opaco.

Lamentablemente, en áreas forestales se puede presentar objetos que no sean humo y tengan el mismo color, entonces sera asimilado como humo real. Este falso positivo es generado principalmente por objetos que no son humo (nubes, neblina o vapor) con el mismo color que el humo, en este caso, un objeto con el color gris puede causar un falso positivo en la detección de humo.

Esto hace que el proceso de detección sea complejo y poco fiable. Por tanto, para validar el humo real, además de utilizar su tono de color, se debe tomar en cuenta características del humo tales como su textura, su forma cambiante y la tasa de crecimiento.

2.3.3. Desafíos en la detección de incendios

Durante la detección de incendios forestales, es posible hacer suposiciones de simplificación sobre la apariencia visual del fuego y humo, que a su vez reducen la complejidad del sistema de detección. Estas hipótesis podrían ser que el fuego y humo tienen una determinada tonalidad de color en las áreas forestales, pero dado que un incendio forestal representa un escenario de desastre, no se puede hacer tales suposiciones generales.

Para detectar con fiabilidad un incendio se deben tomar en cuenta sus siguientes características:

- El fuego y humo no tienen una forma definida y están en constante movimiento.
- En áreas forestales, el fuego y humo presentan una gama de colores definida, pero en el ambiente pueden existir otros objetos con colores similares.
- El humo puede ser fácilmente confundido con neblina, nubes y vapor.
- Pueden existir objetos que obstaculicen la visión del fuego y humo, que no permitan su correcta detección.

Asumimos que, si las condiciones son bastante malas, no va a ser posible que ocurra una detección, independientemente de lo bien que el método de visión por computadora sea usado. Por tanto, una hipótesis de trabajo mínima razonable es que el incendio haya sido captado nítidamente y contenga las características visuales que corresponden a un incendio forestal.

En base a la recopilación de las características y el desafío que representa la detección de incendios, se realiza una descripción de los métodos y técnicas propuestos para la detección visual de incendios forestales, los mismos serán abordados en la siguiente sección.

2.4. Visión por Computador

Según Haralick (1992), la Visión por Computador es la ciencia que desarrolla las bases teóricas y algorítmicas para obtener información sobre el mundo real a partir de una o varias imágenes [1], esta es una definición ideal para el caso de estudio que es la detección de incendios, ya que estamos centrados en definir las técnicas y métodos que nos permitan analizar y procesar imágenes, esto con el afán de resaltar sus características y hacerlas únicas con el medio que las rodea.

Para este proyecto de grado este proceso es critico, ya que los resultados obtenidos en la extracción de características son los que serán utilizados en un modelo de entrenamiento que permita realizar una predicción sobre una imagen nueva.

Esta sección se refiere concretamente a la descripción de los fundamentos teóricos de diferentes técnicas que serán desarrollados durante el proyecto de grado.

2.4.1. Tratamiento de imágenes

Existe muchas funciones para editar imágenes, la mayoría de estas son usadas para optimizar, manipular o retocar las mismas, se usan tres principales funciones para el tratamiento de imágenes. Usando la función de recorte logramos obtener una porción de la imagen que sea de nuestro interés, escalando la imagen lograremos que estas sean del tamaño que deseamos. Es importante tener una cantidad de imágenes de entrenamiento considerable para obtener un mejor modelo de predicción, entonces además de las anteriores se usara una función para reflejar la imagen horizontalmente y una función de rotación, logrando de esta manera obtener una mayor cantidad de imágenes a partir de una sola.

Recorte

El recorte implica la reducción de la imagen, dejando atrás los elementos exteriores para centrar la atención en el tema principal. Dada una imagen de entrada, se establece un tamaño de recorte que queremos obtener (ventana), entonces empezando por la esquina superior izquierda, se obtiene un “recorte” de la imagen de entrada del tamaño de la ventana sin afectar la imagen original, recorremos la ventana hacia la derecha unos cuantos pixels y repetimos el proceso hasta llegar al final de la imagen horizontalmente y verticalmente.



Figura 2.1: Sección de la imagen que sera recortada.

Este proceso permite obtener muchas imágenes dada una imagen de entrada que sea de tamaño mayor, entonces solo queda clasificar estas imágenes obtenidas en sus carpetas correspondientes.

Puesta en Escala

La puesta en escala es la variación del largo y el ancho de una imagen, que en este caso en particular se conservaran las proporciones de la imagen para que esta no quede distorsionada.




Figura 2.2: Colección de imágenes obtenidas después del recorte.




Figura 2.3: Imagen original.

Dada una imagen de entrada, modificamos el largo o ancho proporcionalmente hasta obtener el tamaño de imagen que requerimos para nuestro entrenamiento, en caso de que la imagen de entrada no sea perfectamente proporcional al tamaño que deseamos se realizara un recorte de las partes que queden fuera del mismo.

Con este proceso podemos simular el alejarnos de una imagen o acercarnos a la misma, se debe tomar en cuenta que acercarnos a una imagen ocasionara la perdida de nitidez en el resultado obtenido.



Figura 2.4: Imagen después de la puesta en escala.

Refracción

Este efecto se logra sometiendo una imagen de entrada a un espejo virtual, entonces la imagen reflejada será una diferente a la de entrada ya que los pixels de un lado pasaran al lado opuesto.




Figura 2.5: Imagen original.



Figura 2.6: Imagen reflejada.

Dada una imagen de entrada se crea una imagen del mismo tamaño totalmente vacía, y vamos recorriendo la imagen de entrada desde el pixel que esta mas a la izquierda y hacemos una copia del mismo en el pixel que esta mas a la derecha de la imagen nueva. Repitiendo este proceso por toda la imagen de entrada logramos obtener el reflejo en la imagen de salida.

2.4.2. Descriptor de características

Histogram of Oriented Gradient

Local Binary Patterns

2.5. Aprendizaje Supervisado

El aprendizaje automático (Machine Learning) es una rama de la inteligencia artificial cuyo objetivo es desarrollar técnicas que permitan al computador aprender, se trata de crear programas capaces de generalizar comportamientos a partir de una información no estructurada suministrada en forma de ejemplos.

Uno de los tipos de aprendizaje automático es el aprendizaje supervisado, que se caracteriza por contar con información que especifica qué conjuntos de datos son satisfactorios para el objetivo del aprendizaje. Esto permite reconocer si una imagen dada coincide o no con la imagen que buscamos, para realizar este proceso es necesario cargar al modelo de aprendizaje diferentes imágenes, especificando en el proceso si se trata o no de un incendio.

Entonces las características obtenidas de una imagen de un incendio mediante técnicas y métodos de Visión por Computador serán las que pasaran al modelo de aprendizaje, además se tiene que realizar el mismo proceso con

imágenes que no coincidan con un incendio para enseñarle al modelo que características no pertenecen a un incendio.

Esta sección describe las diferentes técnicas de aprendizaje supervisado que serán utilizados en el desarrollo de este proyecto de grado.

2.5.1. Maquina de Soporte Vectorial

2.5.2. Red Neuronal Artificial

La Red Neuronal Artificial es una técnica de aprendizaje esta inspirado en el sistema nervioso de los animales, donde grupo de nodos interconectados que representa la red neuronal de un cerebro. Cada nodo representa una neurona artificial y una arista representa la sinápsis que existe entre una neurona y otra siendo el medio de transporte de información de una neurona a otra.

Entonces, la entrada de información se encargara de activar neuronas y si estas son disparadas envían impulsos a otras neuronas a las que está conectada, activando o no las adyacentes entonces este proceso se repetira hasta que finalmente llegue a una neurona de decisión que sera activada o no, determinando si la imagen de entrada es la de un incendio.

2.6. Estado del arte

2.7. Resumen del capitulo

En este capítulo se ha proporcionado al lector conceptos que son esenciales para abordar el problema de detección visual de incendios forestales. Debido

a las consecuencias medio ambientales que ocasionan los incendios forestales es importante generar herramientas que ayuden su detección temprana para que puedan ser atendidos rápidamente. Mediante la aplicación de técnicas de visión por computadora es posible obtener las principales características que definen el fuego y humo para de esta manera obtener una colección en base a ejemplos de muestra. Es sobre esta colección de características donde se aplica métodos de Aprendizaje Supervisado obteniendo un modelo entrenado capaz de predecir si una imagen presenta fuego o humo en el mismo.

La revisión sobre las técnicas de Visión por Computadora, han propuesto varios métodos rápidos y fiables que factiblemente pueden ser implementados en un sistema para la detección de incendios en áreas forestales, el siguiente capítulo describe cómo estos son implementados en el sistema.

Capítulo 3

DESARROLLO DEL SISTEMA DE DETECCIÓN

En este capítulo se describe cómo el sistema de detección de incendios es desarrollado mediante el uso de técnicas de Visión por Computador y Aprendizaje Automático.

Las primeras secciones definen el contexto del ambiente de desarrollo, el diseño mediante el cual el sistema es desarrollado donde se presenta una visión completa del funcionamiento del mismo. Después se aplican los métodos elegidos para el desarrollo de cada uno de los procesos principales que contempla el sistema de detección de incendios.

3.1. Contexto del ambiente de desarrollo

El objetivo de este proyecto de grado es la creación de un sistema de detección visual, por tanto, esta basado sólo en la captura de imagen de una cámara ordinaria. Las razones para esta elección es que, el uso de una cámara ordinaria permite realizar pruebas de manera más fácil y rápida, ya que no es

necesario el uso de hardware especial para ejecutarse y el conjunto de datos recolectados durante el desarrollo están disponibles en línea.

Además las cámaras fotográficas normales son más baratas que cámaras térmicas, esto significa que el sistema puede ser implantado a diferentes sistemas a un precio mucho mas accesible.

El sistema fue desarrollado en una computadora personal que tiene las siguientes características:

- Procesador Cuádruple núcleo Intel® Core™ i3-3217U CPU @ 1.80GHz.
- 3,8 GiB de memoria ram.
- Sistema Operativo elementary OS 0.3.2 Freya (64-bit)

Todo el código producido en este proyecto de grado ha sido escrito en Python, que es un lenguaje de programación interpretado que esta enfatizado en la simplicidad y legibilidad de código, que se potencia con el apoyo de poderosas librerías científicas tales como NumPy, SciPy, OpenCV, etc.

3.2. Alcance del sistema de detección

El sistema desarrollado para este proyecto de grado debe ser considerado como una prueba de concepto en lugar de una solución final. Se ha tomado en cuenta a lo largo de todo el proyecto, soluciones parciales y/o totales aplicadas en diferentes investigaciones. Entonces el tiempo de procesamiento es tal vez la mayor restricción impuesta en el sistema ya que idealmente el procesamiento debe suceder en tiempo real.

En base al análisis realizado en el capítulo anterior, el sistema esta restringido al procesamiento de imágenes correspondientes a áreas forestales y no así a situaciones suscitadas en otras áreas.

Además, se evidencia que un sistema de detección de incendios totalmente autónomo no va a funcionar de forma aislada, sino que será parte de un sistema más grande posiblemente bastante complejo que estará bajo supervisión humana. Entonces, el trabajo realizado se ha centrado en la aplicación de software del sistema de detección de incendios en áreas forestales que sólo utiliza la entrada de una cámara ordinaria, software o hardware adicional que corresponda a un sistema más completo esta más allá del alcance de este proyecto de grado.

3.3. Diseño del sistema de detección

Para el sistema de detección diseñado en este proyecto de grado se realizan dos detecciones: un detector de fuego basado en el descriptor HOG y un detector de humo basado en LBP. Ambos realizan la detección mediante el clasificador SVM. Entonces cada una de las detecciones está basada en el diseño presentado en esta sección.

3.3.1. Diagrama de procesos

Para cada una de las detecciones, se genera un modelo clasificador basado en SVM, este será utilizado recién en el sistema de detección donde será aplicado a una imagen completa.

Generación del modelo clasificador

Como se vio en el capítulo anterior, para generar un modelo clasificador se parte de un conjunto de ejemplos con los cuales se realiza el entrenamiento y se hallan los vectores de soporte que permiten realizar una clasificación.

Entonces, dado un conjunto de imágenes se realiza un proceso manual

de anotación para obtener muestras positivas y negativas. Del conjunto de imágenes positivas y negativas, aleatoriamente son asignados en conjuntos de entrenamiento, evaluación y validación.

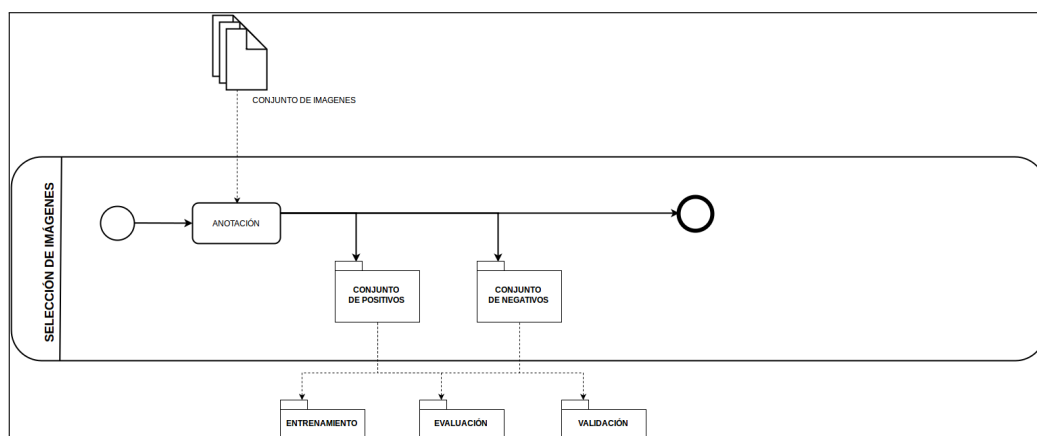


Figura 3.1: Sección de la imagen que sera recortada.

Luego, para cada imagen del conjunto de entrenamiento, se obtiene su descriptor correspondiente con la etiqueta que le corresponde (si es una muestra positiva o negativa) para generar el modelo clasificador y luego hacer las pruebas sobre las mismas imágenes de entrenamiento. En caso de que las pruebas no satisfagan se realiza un refinamiento de muestras de entrenamiento mediante Bootstrapping y Aprendizaje Activo hasta que las pruebas satisfagan en los conjuntos de entrenamiento y evaluación.

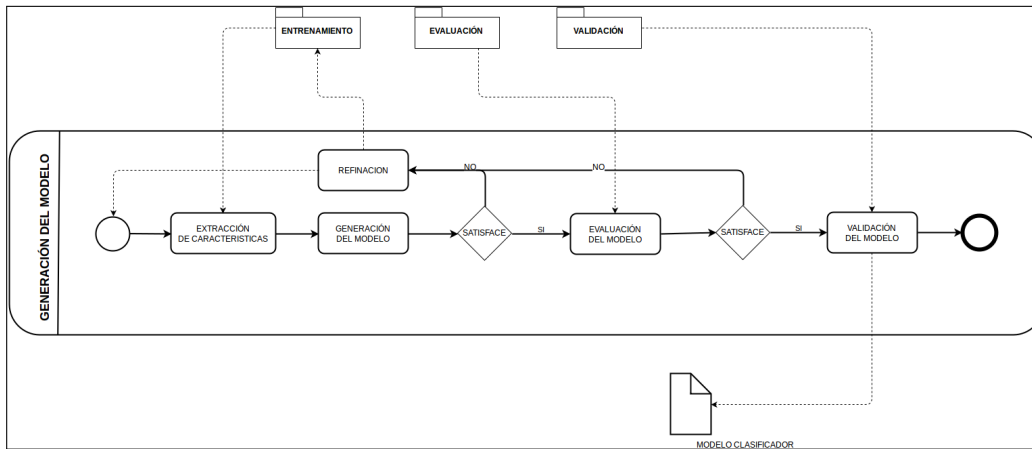


Figura 3.2: Sección de la imagen que sera recortada.

El modelo entrenado que satisfaga los conjuntos de entrenamiento y evaluación es el modelo que se utilizara para la clasificación en el sistema de detección, realizar la clasificación sobre el conjunto de validación permite evaluar el rendimiento del clasificador, se puede ver mas detalles de esto en el capitulo 4.

Sistema de detección

El sistema de detección se aplica sobre una imagen de entrada obtenida con una cámara ordinaria, donde el primer proceso es establecer las regiones de interés dentro de la imagen, entonces se definen los lugares donde podría existir presencia de humo o fuego dentro de la imagen con el uso de técnicas de Visión por Computador relacionados al descriptor de color.

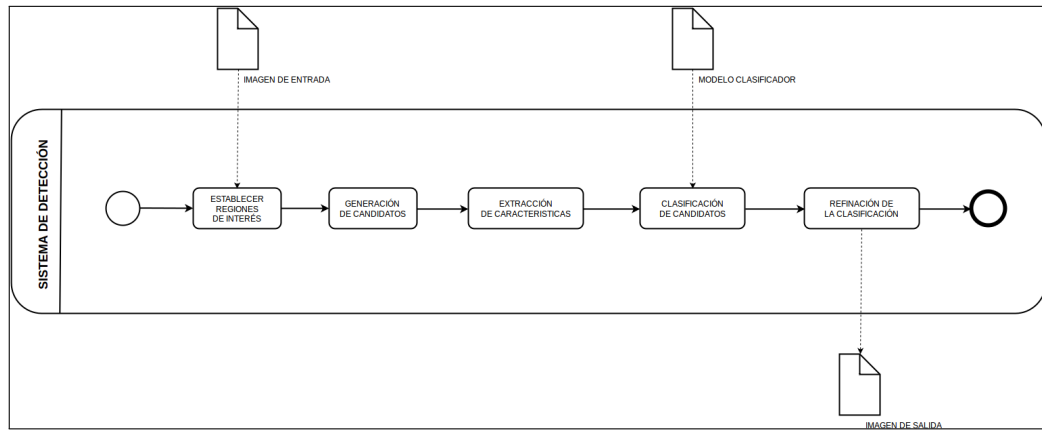


Figura 3.3: Sección de la imagen que sera recortada.

Entonces en base a estas regiones se generan candidatos que serán evaluados por el modelo clasificador. Por cada candidato se obtiene su descriptor y se evalúa con el modelo entrenado para obtener una resultado.

Debido a que un candidato que haya dado positivo puede solapar a otro candidato en cierto porcentaje dentro de la imagen se realiza una refinación de los resultados sobre la imagen, para que estos sean tomados en cuenta como un solo resultado. Después de este proceso se obtiene la imagen resultante con recuadros en las regiones que se hayan detectado fuego o humo.

3.3.2. Rol de actividades

Este es el rol de actividades.

#	Hito	Fecha estimada de entrega
1.	Contexto del ambiente de desarrollo	25 de Mayo
2.	Diseño del sistema	25 de Mayo
3.	Generación del modelo clasificador	16 de Junio
4.	Evaluación del modelo clasificador	16 de Junio
4.	Establecimiento de las regiones de interés	7 de Julio
5.	Generación del candidatos	7 de Julio
6.	Clasificación de candidatos	7 de Julio
7.	Refinación de la clasificación	28 de Julio
7.	Evaluación del sistema de detección	28 de Julio
9.	Tabulación de resultados	11 de Agosto
8.	Entrega preliminar	11 de Agosto
10.	Entrega final	18 de Agosto

Cuadro 3.1: Rol de actividades.

3.4. Generación del modelo

Esta sección describe el proceso seguido para la generación de los modelos clasificadores detectores de humo y fuego.

Un modelo entrenado mediante Aprendizaje Supervisado, es capaz de deducir un resultado a partir de datos de entrenamiento. Entonces elegimos un conjunto de muestras etiquetadas con sus respectivas clases, un porcentaje de estas muestras serán elegidas para el entrenamiento, evaluación y validación del modelo clasificador.

3.4.1. Selección de imágenes

El proceso de anotación se realizara sobre imágenes de incendios en áreas forestales recolectadas de Internet.

Anotación

Algo que caracteriza a un modelo entrado mediante Aprendizaje Supervisado es que solo pueden trabajar con conjuntos de entrenamiento que generen vectores de tamaño fijo. Con el objetivo de cumplir esto es necesario establecer un tamaño fijo para el conjunto de imágenes de entrenamiento. Entonces imágenes que hayan sido seleccionadas que no cumplan con el tamaño elegido, serán procesadas para que cumplan con este requisito.

El fuego y humo no tienen una relación natural en su altura y anchura, es por este motivo que el tamaño canónico establecido para la generación de candidatos serán cuadrados perfectos.

Conjunto entrenamiento, evaluación y validación

De todo el conjunto de imágenes positivas y negativas generadas mediante la anotación, estos serán divididos aleatoriamente en conjuntos que serán utilizados para el entrenamiento, evaluación y validación del modelo clasificador, mediante la siguiente relación:

- El 80 % del del conjunto generado pasan al conjunto de entrenamiento.
- El 10 % del del conjunto generado pasan al conjunto de evaluación.
- El 10 % del del conjunto generado pasan al conjunto de validación.

Los conjunto de entrenamiento y evaluación, son utilizados para la generación de un modelo que se acerque a resultados óptimos durante la clasificación.




Figura 3.4: Sección de la imagen que sera recortada.

El conjunto de validación es un conjunto aislado, donde ninguno de los elementos estuvo involucrado con el entrenamiento del modelo. Este conjunto permite establecer la calidad del modelo clasificador.

3.4.2. Entrenamiento

Primero, de cada elemento del conjunto de entrenamiento se obtienen sus descriptores y se le añade la etiqueta a la cual corresponde (si son muestras positivas o negativas). Estos son almacenados en una matriz donde cada fila es el descriptor de una muestra mas su correspondiente etiqueta y el numero de columnas es la cantidad de muestras de entrenamiento.




Figura 3.5: Sección de la imagen que será recortada.

Esta matriz pasa por el entrenamiento SVM, y genera un modelo entrenado que contiene los vectores de soporte que representan el límite de detección para decir si una muestra es positiva o negativa.

3.4.3. Refinación

Aunque el entrenamiento es generado en un solo paso, nada garantiza la calidad de predicción del mismo, es por este motivo que en un proceso iterativo se refina el entrenamiento hasta que cumpla con los conjuntos de entrenamiento y validación.

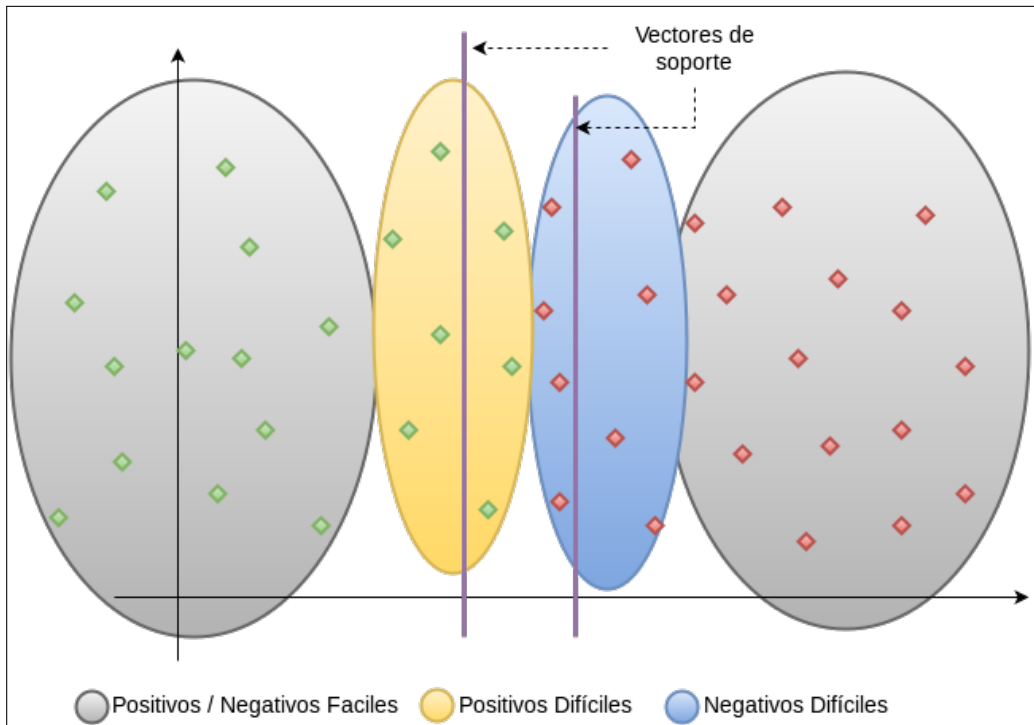


Figura 3.6: Sección de la imagen que sera recortada.

En el plano donde se representan los vectores de soporte hallados por la Máquina de Soporte Vectorial, se puede distinguir ejemplos que se encuentran mas cercanos a los vectores de soporte. Entonces el modelo asume que estos puntos son los mas difíciles de predecir, mientras que un punto que esta alejado de los vectores de soporte, su predicción esta polarizada a positivo o negativo.

Las técnicas de refinación presentadas a continuación pretenden ayudan a refinar los vectores de soporte generados mediante el entrenamiento iterativo, para que la predicción sea mas eficiente.

Bootstrapping

Bootstrapping pone a prueba el modelo clasificador con las muestras negativas del conjunto de entrenamiento en busca de detección de falsos positivos. Entonces todos los resultados que estén próximos a los vectores de soporte (ya sean falsos negativos o falsos positivos) son los negativos difíciles y pasan a ser el nuevo conjunto de negativos para el próximo entrenamiento.

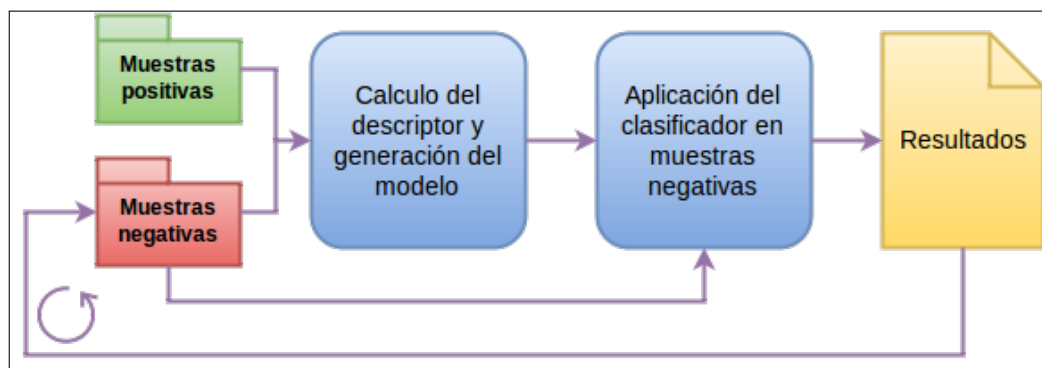


Figura 3.7: Sección de la imagen que será recortada.

De esta manera se evita el peso que generan en el modelo aquellos negativos fáciles (aquellos que están lejos, de los vectores de soporte) y se obtiene un modelo que ajusta mas a la predicción.

En cuanto el modelo ya no detecte falsos positivos, en las muestras negativas del conjunto de entrenamiento, se pasa a realizar el mismo procedimiento sobre el conjunto de evaluación, añadiendo los falsos positivos que se vayan detectando al conjunto de negativos.

Aprendizaje activo

En el Aprendizaje Activo se ponen a prueba las muestras positivas y negativas del conjunto de entrenamiento, de los resultados obtenidos.

De los resultados de las muestras positivas, aquellas que están próximas a los vectores de soporte son los positivos difíciles y estas pasaran a ser las muestras en el conjunto de positivos para el próximo entrenamiento.

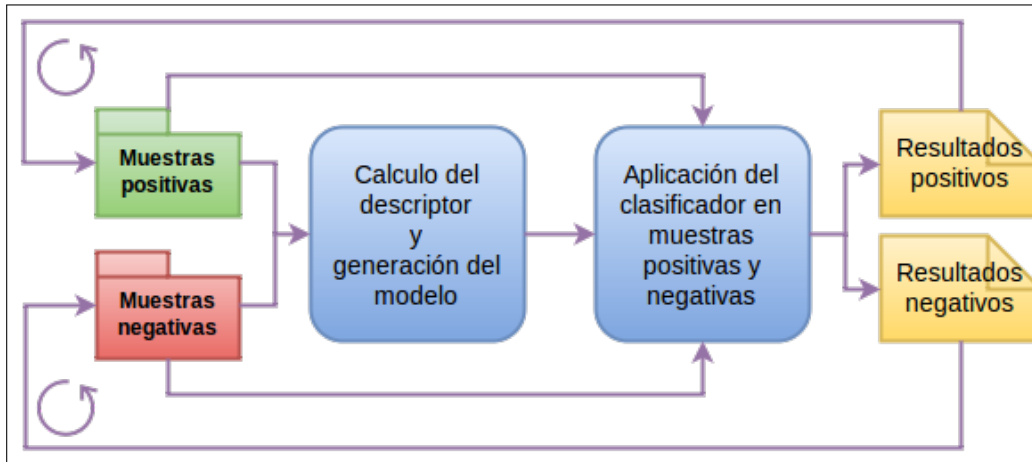


Figura 3.8: Sección de la imagen que sera recortada.

Las pruebas realizadas sobre las muestras negativas, permiten verificar que los nuevos modelos generados no generan falsos positivos ocasionando que el modelo clasificador no haga la predicción de manera correcta. En caso de que se vayan encontrando falsos positivos estos deben ser añadidos al conjunto de negativos para el próximo entrenamiento.

Entonces, el entrenamiento refinado que satisface los conjuntos de entrenamiento y evaluación es el entrenamiento final que sera utilizado en el sistema de detección. En el capítulo 4 se procede a evaluar el rendimiento del modelo clasificador con el conjunto de validación.

3.5. Implementación del sistema de detección

En esta sección se detalla la implementación del sistema de detección de incendios. El sistema realiza la detección sobre una imagen completa, se

seleccionan las regiones que nos interesan analizar con el modelo clasificador. De estas regiones se generan candidatos que el modelo clasificador pueda predecir si es una región que contiene fuego, humo o ninguno de los 2.

3.5.1. Establecer las regiones de interés

Este proceso permite discriminar regiones que no tengan posibilidad de ser fuego o humo. De esta manera mediante el descriptor del color de pixel se obtiene regiones que tengan al menos una ligera posibilidad de ser fuego o humo.

3.5.2. Generación de candidatos

En base a las regiones de interés obtenidas en el proceso anterior, se generan candidatos que son muestras de estas regiones del tamaño correspondiente para poder realizar la detección mediante el modelo clasificador. Las técnicas utilizadas para poder realizar esta detección son la de ventana deslizante y incremento piramidal.

Ventana deslizante

Dado el tamaño canónico elegido para la detección de humo y fuego, se generan candidatos por toda la superficie de las regiones de interés.

Entonces se toma un candidato del extremo superior izquierdo de la región de interés, se define el salto como el recorrido que queremos darle para la generación del siguiente candidato. Este proceso se repite por toda la superficie de cada una de las regiones de interés, obteniendo como resultado una colección de candidatos.

Pirámide

Con el paso anterior se generan todos los candidatos en las regiones de interés, pero solo de tamaño canónico. Entonces si tenemos la presencia de humo o fuego mas cerca, se generaron candidatos que corresponden a la mitad de una imagen de humo o fuego.

Para obtener candidatos que correspondan a diferentes tamaños de la región de interés, se hace un cambio de dimensión a la imagen original (mas pequeño), mantenemos el tamaño de generación de candidatos y se repite el proceso de ventana deslizante sobre la imagen redimensionada. Este proceso se repite hasta que el tamaño de la ventana de generación de candidatos sea mayor a cualquier región de interés del cual se generan candidatos.

3.5.3. Extracción de características

En este punto, se tiene una colección de candidatos de fuego y/o humo que deben ser sometidos a una predicción por sus respectivos modelos de clasificación.

Entonces de cada uno de estos candidatos se obtiene su respectivo descriptor. El descriptor de los candidatos de fuego se obtiene mediante el algoritmo HOG y los de humo mediante el algoritmo LBP.

La colección de candidatos pasa a ser una colección de descriptores y están listos para ser sometidos a una clasificación.

3.5.4. Clasificación de candidatos

El siguiente paso, es la clasificación de la colección de descriptores generados a partir de las regiones de interés. Para ello se carga los modelos clasificadores de fuego y humo entrenados en la sección anterior y cada elemento de la

colección de descriptores debe someterse a la predicción de su correspondiente modelo.

En base a los resultados obtenidos de cada clasificador, se tiene las regiones donde se detecto la presencia de humo o fuego.

3.5.5. Refinación de la clasificación

La clasificación obtenida sobre la imagen en el proceso anterior necesita una refinación por que puede existir cierto porcentaje de solapamiento en las detecciones obtenidas. Entonces definimos un porcentaje mínimo de solapamiento que debe existir para que 2 detecciones sean tomadas como una, recorreremos la colección de detecciones buscando este solapamiento para obtener una clasificación refinada.

3.6. Resumen del capítulo

Capítulo 4

EXPERIMENTACIÓN Y EVALUACIÓN

4.1. Pruebas

4.2. Matriz de confusión

La matriz de confusión es una herramienta que permite la visualización del desempeño del modelo clasificador empleado en el aprendizaje supervisado. Para este caso en particular se tienen dos modelos y cada uno de estos modelos tendrá su matriz de confusión. En la figura ~~acá poner la dirección de la figura~~ cada columna de la matriz representa el número de predicciones de cada clase, mientras que cada fila representa a las instancias en la clase real.



Figura 4.1: Sección de la imagen que sera recortada.

Las instancias de cada clase real son las muestras positivas y negativas del conjunto de validación. En base a estos datos:

1. El cuadro **verdaderos positivos** representa la cantidad de muestras positivas que fueron detectadas como positivas.
2. El cuadro **falsos positivos** representa la cantidad de muestras negativas que fueron detectadas como positivas.
3. El cuadro **falsos negativos** representa la cantidad de muestras positivas que fueron detectadas como negativas.
4. El cuadro **verdaderos negativos** representa la cantidad de muestras negativas que fueron detectadas como negativas.

Estos datos permiten obtener diferentes tipos de datos tales como la precisión, exactitud y la sensibilidad del modelo clasificador.

4.3. Rendimiento del clasificador

Para evaluar el rendimiento del modelo clasificador, utilizamos el conjunto de validación generado durante el proceso de generación del modelo clasificador.

4.3.1. Exactitud

La exactitud es la proximidad del resultado con la clasificación exacta y se representa mediante la siguiente formula:

$$Exactitud = \frac{\#RealesPositivos + \#RealesNegativos}{\#TotalDePredicciones}$$

Modelo clasificador de fuego: 100% de exactitud.

Modelo clasificador de humo: 100% de exactitud.

4.3.2. Precisión

La precisión es la calidad del resultado positivo del clasificador:

$$Exactitud = \frac{\#RealesPositivos}{\#RealesPositivos + \#FalsosPositivos}$$

Modelo clasificador de fuego: 100% de precisión.

Modelo clasificador de humo: 100% de precisión.

4.3.3. Tasa de detección

O Sensibilidad, es la eficiencia en la clasificación de todos los elementos que son de la clase.

$$Exactitud = \frac{\#RealesPositivos}{\#RealesPositivos + \#FalsosNegativos}$$

Modelo clasificador de fuego: Tasa de detección de 100%.

Modelo clasificador de humo: Tasa de detección de 100%.

4.3.4. Especificidad

Es la eficiencia en la clasificación de todos los elementos que no son de la clase.

$$Exactitud = \frac{\#RealesNegativos}{\#RealesNegativos + \#FalsosPositivos}$$

La especificidad permite encontrar la Tasa de error del modelo clasificador mediante la siguiente formula:

$$TasaDeError = 1 - Especificidad$$

Modelo clasificador de fuego: Tasa de error de 100%.

Modelo clasificador de humo: Tasa de error de 100% .

Estos resultados serán analizados en el siguiente capítulo.

4.4. Evaluación del sistema de detección

4.4.1. Tasa de detección

4.4.2. Tasa de Error

4.4.3. Falsos positivos por imagen

4.5. Casos de estudio

Capítulo 5

CONCLUSIONES Y RECOMENDACIONES

BIBLIOGRAFÍA SELECTA U OBRAS CONSULTADAS

Bibliografía

- [1] HARALICK, R., AND SHAPIRO, L. Robot and computer vision (vols. 1 and 2), 1992.